

Analisis Performa Penjualan

Studi kasus retail — pembersihan data, analisis, dan insight bisnis

1. Ringkasan

Studi kasus ini menganalisis dataset penjualan retail sintetis “**Namaste Mart**” (±4.300 transaksi, periode 2020–2024) untuk memahami performa penjualan berdasarkan kategori produk, wilayah, strategi diskon, dan status pemenuhan pesanan. Project ini mencakup keseluruhan alur kerja analytics: pembersihan data menggunakan **SQL (BigQuery)**, eksplorasi data, hingga dashboard interaktif di **Data Studio**.

Tools yang digunakan: Google BigQuery (SQL) untuk pembersihan dan transformasi data, Data Studio untuk dashboard interaktif.

2. Rumusan Masalah

Bagaimana performa Namaste Mart dari sisi revenue dan profitabilitas, serta di mana letak peluang dan risiko terbesar terkait kategori produk, strategi diskon, dan proses pemenuhan pesanan?

Secara spesifik, analisis ini menjawab pertanyaan berikut:

- Kategori produk mana yang menyumbang revenue terbesar, dan apakah kategori dengan revenue tertinggi juga yang paling menguntungkan?
- Apakah pemberian diskon yang lebih besar benar-benar meningkatkan nilai transaksi?
- Berapa besar revenue yang hilang akibat retur dan pembatalan pesanan, dan apakah kerugian ini terkonsentrasi di area tertentu?
- Bagaimana pola tren revenue dan profit bulanan sepanjang periode 2020–2024?

3. Proses Pembersihan Data

Dataset mentah (`retail_sales_dataset.csv`, ±4.310 baris) memiliki berbagai masalah kualitas data yang secara sengaja dibuat menyerupai kondisi data retail di dunia nyata. Setiap masalah diidentifikasi, diinvestigasi, dan diselesaikan menggunakan BigQuery sebelum masuk tahap analisis:

3.1 Format tanggal tidak konsisten

Kolom `order_date` memiliki tiga format berbeda yang tercampur dalam satu kolom: format hari/bulan/tahun (`25/05/2022`), dan format penulisan panjang (`“February 10, 2021”`). Masalah ini diselesaikan menggunakan **COALESCE** dari tiga pola **SAFE.PARSE_DATE**, dengan tambahan **REGEXP_REPLACE** untuk menormalkan spasi tidak wajar.

3.2 Format kategori tidak konsisten

Kolom `gender` memiliki variasi penulisan (`MALE`, `male`, `M`). Kolom `order_status` memiliki inkonsistensi kapitalisasi (`Delivered` vs `delivered`). Keduanya distandarkan menggunakan kombinasi **UPPER/TRIM/CASE** dan fungsi **INITCAP**.

3.3 Data duplikat

Ditemukan 190 baris dengan `order_id` yang duplikat. Setelah diinvestigasi, baris-baris ini merupakan duplikat identik secara keseluruhan (bukan versi update yang berbeda), sehingga aman dihapus menggunakan **ROW_NUMBER()** yang dipartisi berdasarkan `order_id`, dengan menyisakan satu baris per `order_id`.

3.4 Nilai numerik tidak valid

Kolom `quantity` dan `shipping_cost` ditemukan memiliki nilai negatif (misalnya `quantity = -1`). Polanya cukup konsisten (kesalahan tanda minus pada bilangan kecil) sehingga dikoreksi dengan menggunakan **ABS()**. Terpisah dari itu, ditemukan `quantity = 999` pada 8 baris, nilai yang tidak masuk akal untuk satu transaksi retail, diperlakukan sebagai nilai sentinel/placeholder dan dikecualikan dari analisis.

3.5 Data kosong (missing values)

Kolom `age` kosong pada 121 baris ($\pm 2,8\%$) dan diisi menggunakan **median** keseluruhan (lebih tahan terhadap outlier dibanding rata-rata/mean). Kolom `discount_pct` kosong pada 134 baris ($\pm 3,1\%$) dan diisi dengan nilai 0, dengan asumsi bahwa data kosong pada kolom ini berarti transaksi tersebut tidak menggunakan diskon, bukan data yang hilang secara acak.

3.6 Keterbatasan data (didokumentasikan, bukan “diperbaiki”)

Nilai `sales_amount` tidak sepenuhnya sesuai dengan hasil perhitungan $\text{quantity} \times \text{unit_price} \times (1 - \text{discount_pct})$. Hal ini sejalan dengan dugaan adanya noise acak yang sengaja disisipkan pada dataset sintetis ini (misalnya mensimulasikan pembulatan, biaya tambahan, atau penyesuaian di titik penjualan), bukan disebabkan kesalahan proses pembersihan data. `sales_amount` dan profit tetap digunakan apa adanya, dan keterbatasan ini didokumentasikan secara transparan alih-alih “dikoreksi” tanpa rumus yang benar-benar terverifikasi.

4. Metodologi

Pada tahap awal, project ini sempat mengeksplorasi segmentasi pelanggan berbasis RFM (Recency, Frequency, Monetary). Pendekatan ini kemudian tidak dilanjutkan sebagai fokus utama setelah ditemukan bahwa mayoritas besar pelanggan hanya memiliki frekuensi pembelian sebesar 1 kali, membuat dimensi Frequency tidak cukup diskriminatif secara statistik untuk dataset ini. Alih-alih memaksakan narasi customer retention yang tidak didukung data, analisis dialihkan fokus ke performa penjualan revenue, profitabilitas, strategi diskon, dan pemenuhan pesanan di mana data menunjukkan pola yang jelas dan didukung bukti yang kuat.

Seluruh metrik di bawah ini mengecualikan pesanan berstatus Returned dan Cancelled, kecuali disebutkan lain, karena pesanan yang dibatalkan tidak merepresentasikan revenue yang benar-benar terealisasi.

5. Temuan Utama

5.1 Revenue terkonsentrasi pada satu kategori yang justru memiliki margin paling tipis

Kategori **Electronics** menyumbang porsi revenue terbesar dengan selisih yang jauh dibanding kategori lain, namun memiliki persentase profit margin terendah di antara semua kategori ($\pm 11,92\%$). Kategori dengan revenue jauh lebih kecil seperti Sports dan Beauty justru menunjukkan profit margin yang jauh lebih tinggi. Ini adalah temuan paling penting dalam analisis ini: kategori penyumbang penjualan terbesar bukanlah kategori dengan profit terbaik.

5.2 Diskon lebih besar tidak meningkatkan nilai transaksi

Pengelompokan transaksi ke dalam tier diskon (No Discount, Low 1–15%, Medium 16–30%, High >30%) menunjukkan bahwa rata-rata nilai transaksi tertinggi justru terjadi pada kelompok **No Discount**, dan terus menurun seiring naiknya tier diskon meskipun volume pesanan meningkat seiring pemberian diskon. Ini mengindikasikan bahwa strategi diskon saat ini kurang efektif dalam mendorong nilai pembelian yang lebih besar, dan berpotensi hanya mengurangi margin pada transaksi yang sebenarnya akan tetap terjadi tanpa diskon.

5.3 Revenue hilang akibat retur/pembatalan cukup signifikan dan didominasi Electronics

Total revenue yang hilang akibat pesanan berstatus Returned dan Cancelled mencapai sekitar **47,2 juta** sekitar **20%** dari total pendapatan kotor. Kategori Electronics kembali menyumbang porsi cukup besar dari pendapatan yang hilang ini (**23,48%**), sejalan dengan porsi besarnya terhadap total volume penjualan.

5.4 Return rate relatif konsisten di semua kategori dan metode pembayaran

Berbeda dengan profit margin, tingkat retur/pembatalan ($\pm 20\text{--}25\%$) relatif konsisten di seluruh kategori produk maupun metode pembayaran, tanpa ada outlier yang menonjol. Ini mengindikasikan bahwa masalah retur kemungkinan besar bersifat sistemik terkait proses pemenuhan pesanan, logistik, atau kebijakan retur bukan masalah kualitas yang spesifik pada satu kategori produk atau kanal pembayaran tertentu.

5.5 Revenue dan profit mengalami perumbuhan jangka panjang

Revenue dan profit menunjukkan tren pertumbuhan jangka panjang dari 2020 ke 2024, dengan fluktuasi bulanan yang signifikan namun tanpa pola musiman yang konsisten berulang tiap tahun. Puncak tertinggi tercapai mendekati pertengahan 2024, mengindikasikan momentum bisnis yang terus menguat sepanjang periode observasi.

6. Rekomendasi

- **Investigasi struktur biaya dan penetapan harga Electronics** dengan margin sebesar $\pm 11,92\%$ pada kategori dengan revenue terbesar perlu ditelaah lebih dalam (biaya supplier atau promosi khusus kategori yang menggerus margin).
- **Evaluasi ulang strategi diskon** karena tier diskon yang lebih tinggi justru berkorelasi dengan nilai transaksi rata-rata yang lebih rendah, pertimbangkan uji coba promosi yang lebih tertarget berbasis threshold (misalnya diskon hanya berlaku di atas nilai belanja minimum), dibanding diskon flat untuk semua transaksi.
- **Audit proses pemenuhan pesanan dan retur secara menyeluruh** karena tingkat retur konsisten di semua lini, perbaikan kemungkinan besar perlu dilakukan pada sisi operasional (pengiriman, kemasan, kejelasan kebijakan retur), bukan pada produk tertentu.
- **Analisis faktor yang mendorong pertumbuhan pada peak 2024** berdasarkan kategori, wilayah, kota, metode pembayaran, dan tingkat diskon.

7. Keterbatasan

- Dataset bersifat sintesis; angka-angka yang ditampilkan sebaiknya dibaca sebagai ilustrasi metode analisis, bukan sebagai angka operasional bisnis riil.
- Kolom sales_amount/profit memiliki variansi yang belum menjelaskan dibanding komponen pembentuknya (lihat Bagian 3.6). Perbandingan margin antar kategori dapat diandalkan secara arah/tren, namun persentase pastinya perlu dibaca dengan catatan ini.
- Data frekuensi pembelian pelanggan terlalu terkonsentrasi pada nilai 1, sehingga tidak cukup mendukung analisis repeat-purchase atau customer churn pada dataset ini. Alur analisis tersebut sengaja tidak dilanjutkan lebih jauh.
- Analisis mencakup periode 2020–2024 sebagaimana tercatat dalam dataset tidak dilakukan perbandingan dengan benchmark industri retail eksternal.

8. Lampiran: Query SQL Utama

Cuplikan query yang digunakan dalam analisis ini. Kumpulan query lengkap tersedia terpisah di file SQL project.

8.1 Pembersihan data (cuplikan)

```
CREATE OR REPLACE TABLE `namaste-mart-506509.namaste.master_clean_data` AS
SELECT order_id,
  COALESCE(
    SAFE.PARSE_DATE('%Y-%m-%d', REGEXP_REPLACE(TRIM(order_date), r'\s+', ' ')),
    SAFE.PARSE_DATE('%d/%m/%Y', REGEXP_REPLACE(TRIM(order_date), r'\s+', ' ')),
    SAFE.PARSE_DATE('%B %d, %Y', REGEXP_REPLACE(TRIM(order_date), r'\s+', ' '))
  ) AS order_date, ... ABS(quantity) AS quantity, ...
FROM `namaste-mart-506509.namaste.master`
WHERE order_id IS NOT NULL AND customer_id IS NOT NULL AND quantity != 999;
```

8.2 Profit margin per kategori

```
SELECT product_category,
  SUM(sales_amount) AS total_revenue,
  ROUND(SUM(profit)/NULLIF(SUM(sales_amount),0)*100,1) AS profit_margin_pct
FROM master_clean_data WHERE order_status != 'Cancelled'
GROUP BY product_category ORDER BY profit_margin_pct DESC;
```

8.3 Return rate per kategori

```
SELECT product_category,
  COUNTIF(order_status IN ('Returned','Cancelled'))
  / COUNT(DISTINCT order_id) * 100 AS return_rate_pct
FROM master_clean_data GROUP BY product_category;
```

Disusun sebagai bagian dari portofolio data analyst. Dashboard: Data Studio tautan tersedia di README project.